Московский государственный технический университет им. Н.Э. Баумана Кафедра «Системы обработки информации и управления»

Лабораторная работа ⊠1 по дисциплине «Методы машинного обучения» на тему «Разведочный анализ данных. Исследование и визуализация данных»

Выполнил: студент группы ИУ5-14М Зубаиров В. А.

```
In [27]: import pandas as pd
         import numpy as np
         from matplotlib import pyplot as plt
         import seaborn as sns
         import plotly.offline as py
         import warnings
         import pycountry
         warnings.filterwarnings('ignore')
         py.init_notebook_mode(connected=True)
         import plotly.graph_objs as go
In [2]: PATH = 'DATA/athlete_events.csv'
        data = pd.read_csv(PATH)
        data.head(3)
Out[2]:
           TD
                                                                         NOC
                                           Age Height
                                                         Weight
                               Name Sex
                                                                    Team
        0
            1
                                          24.0
                                                 180.0
                                                           80.0
                                                                           CHN
                          A Dijiang
                                       М
                                                                   China
        1
            2
                           A Lamusi
                                          23.0
                                                 170.0
                                                           60.0
                                                                   China
                                                                           CHN
        2
                                          24.0
            3
               Gunnar Nielsen Aaby
                                       М
                                                   NaN
                                                            NaN Denmark
                                                                           DEN
                  Games
                         Year
                               Season
                                             City
                                                         Sport
           1992 Summer
                         1992
                               Summer
                                        Barcelona
                                                   Basketball
        0
           2012 Summer
        1
                         2012
                               Summer
                                           London
                                                          Judo
           1920 Summer
                         1920
                               Summer
                                        Antwerpen
                                                      Football
                                    Event Medal
        0
            Basketball Men's Basketball
                                            NaN
           Judo Men's Extra-Lightweight
        1
                                            NaN
                Football Men's Football
        2
                                            NaN
In [4]: data.shape
Out[4]: (271116, 15)
In [3]: data.describe()
Out[3]:
                           ID
                                                       Height
                                                                       Weight
                                          Age
               271116.000000
                               261642.000000
                                               210945.000000
                                                               208241.000000
        count
                68248.954396
                                    25.556898
                                                   175.338970
                                                                   70.702393
        mean
        std
                 39022.286345
                                     6.393561
                                                    10.518462
                                                                    14.348020
                     1.000000
                                    10.000000
                                                   127.000000
                                                                   25.000000
        min
        25%
                34643.000000
                                    21.000000
                                                   168.000000
                                                                   60.000000
        50%
                68205.000000
                                    24.000000
                                                  175.000000
                                                                   70.000000
               102097.250000
        75%
                                    28.000000
                                                   183.000000
                                                                   79.000000
                                    97.000000
               135571.000000
                                                  226.000000
                                                                  214.000000
        max
                         Year
        count
               271116.000000
        mean
                  1978.378480
                    29.877632
        std
```

min	1896.000000
25%	1960.000000
50%	1988.000000
75%	2002.000000
max	2016.000000

The dataset has the following features:

ID - Уникальный номер атлета

Name - Имя атлета

Sex - Пол Атлета

Age - Возраст

Height - Рост

Weight - Bec

Team - Название команды

NOC - Код НОК

Games - Год/Время года

Year - Год

Season - Летние или зимние

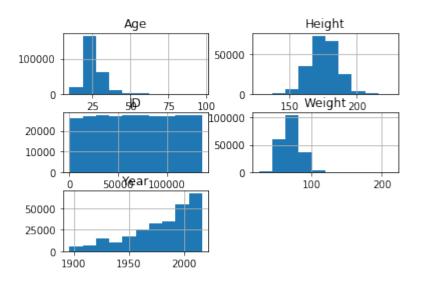
City - Место проведения

Sport - Вид спорта

Event - событие

Medal - Медаль

In [7]: data.hist()



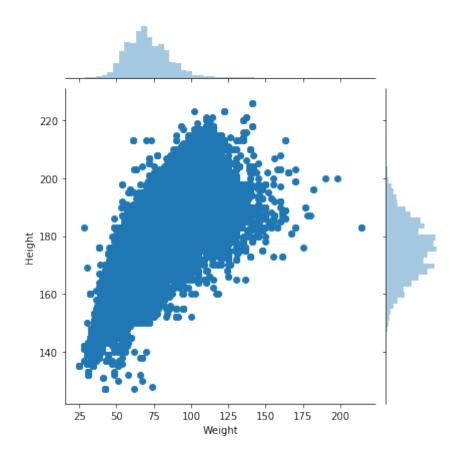
0.1. Корреляция численных признаков

In [9]: data.corr()

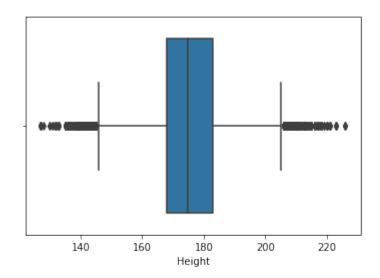
```
Out[9]:
                     ID
                              Age
                                     Height
                                              Weight
                                                          Year
               1.000000 -0.003631 -0.011141 -0.009176 0.011885
       ID
              -0.003631
                         1.000000 0.138246 0.212069 -0.115137
       Age
       Height -0.011141
                         0.138246 1.000000 0.796213
                                                      0.047578
       Weight -0.009176 0.212069 0.796213
                                             1.000000
                                                      0.019095
       Year
               0.011885 -0.115137 0.047578 0.019095
                                                      1.000000
```

In [32]: sns.jointplot(x='Weight', y='Height', data=data)

Out[32]: <seaborn.axisgrid.JointGrid at 0x13be5dcd0>



Out[11]: <matplotlib.axes._subplots.AxesSubplot at 0x1215b1650>



In [20]: sns.boxplot(x="Sex", y="Height", data=data)

Out[20]: <matplotlib.axes._subplots.AxesSubplot at 0x13386c9d0>

